



南京工业大学
NANJING TECH
UNIVERSITY

用户数据采集与关联分析

(结课作业)

信管2301

施越杨

202321054018



第一讲 课程导言与分词

1. 学习使用在线NLPIR分词系统或微词云分词或清华大学分词演示系统；

THULAC：一个高效的中文词法分析工具包

欢迎使用THULAC中文分词工具包demo系统

黄旭华，1926年3月12日出生于广东省汕尾市，原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室副总工程师、中船重工集团公司核潜艇总体设计所研究员、名誉所长。1994年当选为中国工程院院士。

测试 Try

黄旭华_np , _w 1926年_t 3月_t 12日_t 出生_v 于_p 广东省汕尾市_ns , _w 原籍_n 广东省_ns 揭阳市_ns , _w 1949年_t 毕业_v 于_p 上海交通大学_ni , _w 历任_v 北京_ns 海军_n 核潜艇_n 研究室_n 副总_j 工程师_n , _w 中_f 船_n 重工_j 集团公_n 司_n 核潜艇_n 总体_n 研究_v 设计所_n 研究员_n , _w 名誉_n 所长_n , _w 1994年_t 当选_v 为_v 中国_ns 工程院_n 院士_n

词性解释

n/名词 np/人名 ns/地名 ni/机构名 nz/其它专名
m/数词 q/量词 mq/数量词 t/时间词 f/方位词 s/处所词
v/动词 vm/能愿动词 vd/趋向动词 a/形容词 d/副词
b/前接成分 k/后接成分 i/习语 j/简称
r/代词 c/连词 p/介词 u/助词 y/语气助词
e/叹词 o/拟声词 g/语素 w/标点 x/其它

解释


版权所有：清华大学自然语言处理与社会人文计算实验室
Copyright: Natural Language Processing and Computational Social Science Lab, Tsinghua University

经济与管理学院

1/3/2026

第一讲 课程导言与分词

2. 安装python（anaconda）（编写输出“Hello World. Hello ‘你的姓名’”）；



The screenshot shows the JupyterLab interface. At the top, it says "jupyter Untitled1 Last Checkpoint: 53 seconds ago". Below this is a menu bar with "File", "Edit", "View", "Run", "Kernel", "Settings", and "Help". To the right of the menu bar is a "Trusted" button. Below the menu bar is a toolbar with various icons for file operations and code execution. The main area contains a code cell with the following text:

```
[1]: print("Hello World. Hello 施越杨")
```

Below the code cell, the output is displayed:

```
Hello World. Hello 施越杨
```

At the bottom, there is an input field for the next code cell, labeled "[]:", and a toolbar with icons for cell operations.

第一讲 课程导言与分词

3. 完成课后作业（001-004，4份代码的运行

[illegible]

Jupyter 002-word_cut_科学家文本 Last Checkpoint: 3 minutes ago Not Truncated

File Edit View Run Kernel Settings Help Python 3 (ipykernel)

```
[2]: import jieba

[3]: seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室副总工程师、中船重工集团公司核潜艇总体/研究/设计所/研究员、/名誉/所长、/1994/年/当选/为/中国工程院院士。')

[4]: print('/'.join(seg_list_huang))

Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\谁越彬\AppData\Local\Temp\jieba.cache
Loading model cost 0.690 seconds.
Prefix dict has been built successfully.
黄旭华/, /1926/年/3/月/12/日/出/生/于/广/东/省/汕/尾/市/, /原/籍/广/东/省/揭/阳/市/, /1949/年/毕/业/于/上/海/交/通/大/学/, /历/任/北/京/海/军/核/潜/艇/研/究/室/副/总/工/程/师/, /中/船/重/工/集/团/公/司/核/潜/艇/总/体/研/究/设/计/所/研/究/员/, /名/誉/所/长/, /1994/年/当/选/为/中/国/工/程/院/院/士/.

[5]: # 加入用户词典

[6]: jieba.load_userdict('dict.txt')

[7]: seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室副总工程师、中船重工集团公司核潜艇总体/研究/设计所/研究员、/名誉/所长、/1994/年/当选/为/中国工程院院士。')

[8]: print('/'.join(seg_list_huang))

黄旭华/, /1926/年/3/月/12/日/出/生/于/广/东/省/汕/尾/市/, /原/籍/广/东/省/揭/阳/市/, /1949/年/毕/业/于/上/海/交/通/大/学/, /历/任/北/京/海/军/核/潜/艇/研/究/室/副/总/工/程/师/, /中/船/重/工/集/团/公/司/核/潜/艇/总/体/研/究/设/计/所/研/究/员/, /名/誉/所/长/, /1994/年/当/选/为/中/国/工/程/院/院/士/.

[9]: # 加入词典之后, 哪些词汇被分离出来了呢?

[10]: # 使用停用词表

[11]: # stopwords = [line.strip() for line in open('stop_words.txt', 'r', encoding='utf-8').readlines()]

[12]: stopwords = open('stop_words.txt', 'r', encoding='utf-8').read()
stopwords = stopwords.split('\n')

[13]: stopwords

[14]: ['的', '了', '是', '啊', ',', '.', ':', ';', '，', '；', '：', '。']

[15]: seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室副总工程师、中船重工集团公司核潜艇总体/研究/设计所/研究员/名誉/所长/1994/年/当选/为/中国工程院院士。')

[16]: final = ''

for seg in seg_list_huang:
    if seg not in stopwords:
        final += seg + '/'

print(final)

黄旭华/1926/年/3/月/12/日/出/生/于/广/东/省/汕/尾/市/原/籍/广/东/省/揭/阳/市/1949/年/毕/业/于/上/海/交/通/大/学/历/任/北/京/海/军/核/潜/艇/研/究/室/副/总/工/程/师/中/船/重/工/集/团/公/司/核/潜/艇/总/体/研/究/设/计/所/研/究/员/名/誉/所/长/1994/年/当/选/为/中/国/工/程/院/院/士/

作业的寓意:


- 你可以处理比较复杂的文本啦
- 你开始尝试接触和理解, 一些具有文化内涵的科技文献资源

```

第一讲 课程导言与分词

```
jupyter 003-NER-企业年报-数字技术-安全管理 Last Checkpoint: 6 minutes ago
File Edit View Run Kernel Settings Help
JupyterLab Python 3 (ipykernel)
[1]: import jieba
     from collections import Counter

[2]: # 文本
     text = """
     落实“企业管理中”主题，加强QMS体系建设，
     通过自动化、数字化、智能化升级改造加快新一代信息技术与全生产经营融合，
     打造精益制造能力，提升精细化管理水平，助力会员从“制造”升级为“智造”，
     从而提高经营效率和效益；通过集团一体化智能管理平台建设与运营，
     丰富企业供应链管理、生产工艺控制等管理工具，不断增强生产过程数据获取与分析能力，
     强化全过程一体化管理，提高自动化、数字化、智能化的供应链管理能力和
     为体系安全稳定运行与管理水平提升保驾护航，致力打造安全智能化工厂；
     打造助用互联网技术合作和商务合作平台，构建具有国际竞争力的供应链体系。
     """

[3]: # 1. 分词处理
     words = jieba.lcut(text)

     Building prefix dict from the default dictionary ...
     Loading model from cache C:\Users\...\AppData\Local\Temp\jieba.cache
     Loading model cost 8.734 seconds.
     Prefix dict has been built successfully.

[4]: words

[4]: ['\n',
     '落实',
     '',
     '企业',
     '管理',
     '与',
     '主题',
     '，',
     '加强',
     'QMS',
     '，',
     '体系',
     '建设',
     '，',
     '\n',
     '通过',
     '，',
     '自研']

[5]: # 2. 定义要统计的关键词
     target_words = ["数字化", "智能化", "安全"]

[6]: # 统计词频
     word_counts = Counter(words)

[7]: # 输出特定词汇的词频统计结果
     print(f"特定词汇词频统计结果:")
     for word in target_words:
         print(f"{word}: {word_counts[word]}次")

     特定词汇词频统计结果:
     *数字化*: 2次
     *智能化*: 3次
     *安全*: 2次

[8]: # 输出所有词汇的词频 (按照频率降序)
     print(f"\n所有词汇词频统计 (前20个): ")
     for word, count in word_counts.most_common(20):
         print(f"{word}: {count}次")

     所有词汇词频统计 (前20个):
     * : 13次
     * :
     * : 9次
     *管理*: 5次
     * : 5次
     *与*: 4次
     ""*: 3次
     *企业*: 3次
     ""*: 3次
     *体系*: 3次
     *智能化*: 3次
     *经营*: 3次
     *打造*: 3次
     *能力*: 3次
     *供应链*: 3次
     *建设*: 2次
     *通过*: 2次
     *自研*: 2次
     *数字化*: 2次
     *自研*: 2次
     *生产*: 2次
```

```
jupyter 004-使用大语言模型提取科技文献中的实体 Last Checkpoint: 9 minutes ago
File Edit View Run Kernel Settings Help
JupyterLab Python 3 (ipykernel)
[1]: import requests
     import json

     # 定义DeepSeek API的URL和headers
     DEEPSEEK_API_URL = "https://api.deepseek.com/v1/chat/completions"
     API_KEY = "sk-84b744631484a38bd774d4739550a87" # 直接复制过来

[2]: # 准备prompt和论文文本
     paper_text = """
     随着肿瘤免疫微环境 (Tumor Immune Microenvironment, TIME) 研究的深入，
     T细胞耗竭 (T cell exhaustion) 被认为是限制免疫治疗效果的关键机制之一。
     本研究基于免疫编辑理论，提出了一种基于单细胞RNA测序 (scRNA-seq) 的T细胞状态动态识别方法。
     具体而言，我们使用Seurat和Monocle3等生物信息学工具对50例非小细胞肺癌患者的肿瘤样本进行细胞亚群聚类及轨迹分析，
     结合pseudotime推断T细胞从激活到耗竭的转化过程。此外，借助CellChat软件构建细胞间通讯网络，
     进一步识别可能诱导T细胞耗竭的免疫抑制信号通路，如PD-1/PO-L1和TGF-β路径。研究结果揭示了T细胞功能衰竭的关键节点，并为个体化免疫治疗提供了潜在靶点。
     """

     prompt = f"""
     请从以下科技论文文本中提取包含理论、方法、工具的实体或专业术语，以json字典的格式输出：

     {paper_text}
     """

[3]: # 准备请求数据
     data = {
         "model": "deepseek-chat",
         "messages": [
             {"role": "user", "content": prompt}
         ],
         "temperature": 0.3
     }

     headers = {
         "Content-Type": "application/json",
         "Authorization": f"Bearer {API_KEY}"
     }

     # 发送请求
     response = requests.post(DEEPSEEK_API_URL, headers=headers, data=json.dumps(data))

[4]: # 处理响应
     if response.status_code == 200:
         result = response.json()
         try:
             entities = result['choices'][0]['message']['content']
             print("提取到的实体和专业术语:")
             print(entities)
         except KeyError:
             print("无法解析API响应，原始响应:")
             print(result)
     else:
         print(f"请求失败，状态码: {response.status_code}")
         print(response.text)

     提取到的实体和专业术语:
     ..json
     {
       "理论": [
         "肿瘤免疫微环境",
         "T细胞耗竭",
         "免疫编辑理论"
       ],
       "方法": [
         "单细胞RNA测序",
         "细胞亚群聚类",
         "轨迹分析",
         "pseudotime推断",
         "细胞间通讯网络构建"
       ],
       "工具": [
         "Seurat",
         "Monocle3",
         "CellChat"
       ],
       "专业术语": [
         "TIME",
         "scRNA-seq",
         "非小细胞肺癌",
         "PD-1/PO-L1",
         "TGF-β路径",
         "免疫抑制信号通路",
         "个体化免疫治疗"
       ]
     }
     ..
```

第一讲 课程导言与分词

4. 阅读压缩文件中（“实体抽取论文-换成PDF”）中的其中一篇论文，并做阅读总结（**仅信管**）。《基于学术论文全文的研究方法实体自动识别研究》

研究方法的规范程度是衡量学科成熟度的重要标志。在情报学领域，虽然研究方法的理论与规范性研究逐渐受到重视，但利用量化方法进行实证分析的研究相对缺乏。对学术论文中提及的研究方法实体进行自动识别与分类，有助于学者快速把握论文主旨，并梳理学科内研究方法的演变与发展模式。因此，本文聚焦于从学术论文全文中自动识别研究方法实体，并将其区分为 **论文使用的研究方法**（用于解决本文研究问题的方法、工具、技术等）和 **论文引用的研究方法**（被引文献中提出或使用的方法、工具、技术等）。

本研究成功实现了从学术论文全文中自动识别研究方法实体。通过系统比较，确定了针对“使用”和“引用”两类实体的最优深度学习模型。对《情报学报》的实证分析表明，**情报学学科中与实验法相关的研究方法**，无论是在使用频次还是引用频次上，**都占据最高比例**，反映了该领域较强的实证研究倾向。

第二讲 词频统计

1. 基于CNKI数据库统计分析2014-2024年（近10年），“信息资源管理”或“网络营销”或其他你感兴趣的主题变化趋势。

总库 9115 中文 6118 外文 1997 学术期刊 6118 学位论文 1650 会议 199 报纸 72 年鉴 515 图书 8 专利 标准 法律法规

主题 来源类别 学科 年度

搜索范围: 总库 主题: 信息资源管理 主题定制 检索历史 共找到 9,115 条结果 1/300

排序: 相关度 发表时间 被引 下载 综合 显示 20

题名	作者	来源	发表时间	数据库	被引	下载	操作
1 轨道角动量模式复用关键技术研究	蓝世财	南京邮电大学	2025-10-10	硕士	4		
2 新时代背景下做好电力档案编研工作的几点思考	姜迪	黑龙江档案	2024-12-30	期刊	14		
3 浅析县级疾控档案信息化管理的新思路	赵爱萍	黑龙江档案	2024-12-30	期刊	6		
4 GIS技术在水利信息化管理中的应用研究	倪云飞	水上安全	2024-12-28	期刊	1	199	
5 融合交通信息的燃料电池汽车能量管理研究进展	王亚敏;范依欣;张俊	汽车工程	2024-12-25	期刊	5	574	
6 企业档案数字化建设中的信息资源整合与共享机制	刘莎	现代企业文化	2024-12-25	期刊	33		
7 数智时代财务赋能拓展的探索	吴禹疆	中国市场	2024-12-18	期刊	1	129	
8 档案信息化对档案工作的影响及挑战分析	孙晓	兰台世界	2024-12-15	期刊	3	70	
9 图书情报类学术期刊论文热点探析——基于图情类期刊和《情报探索》的对比分析	陈静;黄浩海;张忠俊;吴京锐	情报探索	2024-12-15	期刊	1	326	
10 健康中国战略下医学院校信息管理类本科人才培养模式研究	晁光;吴尚	情报探索	2024-12-15	期刊		185	
11 基于数字孪生的实验室资源共享平台设计与实现	王鹏;李斯	信息系统工程	2024-12-15	期刊	2	156	
12 我国风险勘查资本市场形势与战略	李瑞宇;张福成;刘仁斌;宋崇宇;常杨	中国矿业	2024-12-15	期刊	2	98	
13 一级学科更名为信息资源管理背景下档案学科发展路径探析	杨华	山东档案	2024-12-15	期刊	1	91	

中国知网 CNKI 中国知识基础设施工程 www.cnki.net CNKI 知识网络服务平台 KNS

中国学术文献网络出版总库 跨库检索 检索首页 中国学术文献网络出版总库

快速检索 标准检索 专业检索 作者发文检索 科研基金检索 句子检索 文献来源检索

1. 输入检索控制条件:

发表时间: 从 2014-01-01 到 2024-12-31 更新时间: 不限

文献来源: 输入来源名称 模糊

支持基金: 输入基金名称 模糊

作者: 输入作者姓名 精确 作者单位: 输入作者单位, 全称、简称、曾用名均可 模糊

2. 输入内容检索条件:

主题: 信息资源管理 词频 并且包含 输入检索词 词频 精确

在结果中检索 检索文献 中英文扩展检索

您可以按如下文献分组排序方式选择文献: (分组只对前4万条记录分组, 排序只在800万条记录以内有效)

文献分组浏览: 来源数据库 学科类别 研究层次 文献作者 作者单位 中文关键词 研究资助基金 发表年度

文献排序浏览: 相关度 发表时间 被引频次 下载频次 每页记录数: 10 20 50

共有记录3180条 首页 上页 下页 全选 清除 存盘

序号	题名	作者	来源	发表时间	来源数据库	被引频次	下载频次
1	从“是什么”到“为什么”: 信息资源管理学科的因果推断探索	步一	情报理论与实践	2024-07-17 16:37	期刊	0	544
2	数据为基: 信息资源管理学科知识体系的重构策略	李帅	图书馆论坛	2024-07-17 11:30	期刊	0	564
3	人工智能生成内容(AIGC)的本质属性及其对信息资源管理学科的影响	朱禹	信息资源管理学报	2024-09-19 10:15	期刊	0	2625
4	加强信息资源管理, 助力新质生产力	李广建	图书情报知识	2024-11-05 09:58	期刊	0	1148
5	基于BERTopic模型的国内信息资源管理研究主题挖掘与演化分析	杨思洛	情报科学	2024-05-07 14:24	期刊	0	4257
6	基于数智教育生态的信息资源管理研究生培养模式研究	刘冰	情报科学	2024-10-08	期刊	0	1054

第二讲 词频统计

2.完成ppt中的程序运行，包括全文词频统计，指定类型词频统计；

```
Jupyter tf1_full_text_sanguo Last Checkpoint: 5 minutes ago
File Edit View Run Kernel Settings Help
[16]: articleDict
{'刀箭': 2,
 '金珠': 7,
 '魔星': 1,
 '以天書': 1,
 '相敬': 1,
 '泛論': 1,
 '駭顧': 1,
 '射目': 1,
 '作史': 1,
 '夾衣': 4,
 '見莊': 1,
 '神仙中人': 1,
 '帝大驚': 1,
 '子康': 1,
 '奉宗廟': 1,
 '贈人': 1,
 '大業': 1,
 '井中': 2,
 '...': 4}

[17]: articleList = sorted(articleDict.items(),key = lambda x:x[1], reverse = True) # 对词典中的词排序

[18]: # 输出词频的前N个
for i in range(100):
    print(articleList[i])

('金珠', 7)
('吕布', 60)
('曹操', 59)
('袁紹', 57)
('天下', 53)
('衣冠', 48)
('劉備', 37)
('太守', 36)
('朝廷', 32)
('孫堅', 31)
('不可', 31)
('次日', 26)
('引兵', 25)
('李儒', 25)
('商議', 25)

[5]: data_name[:70]
[5]: '諸葛亮|關羽|劉備|曹操|孫權|關羽|張飛|呂布|周瑜|趙雲|龐統|司馬懿|黃忠|馬超'
[6]: print(data_name[:50])
諸葛亮|關羽|劉備|曹操|孫權|關羽|張飛|呂布|周瑜|趙雲|龐統|司馬懿|黃忠|馬超
[7]: f_name.close()
[8]: # 將文本转化为列表
[9]: names = data_name.split('|') # split一下names就是列表
[10]: print(names)
['諸葛亮', '關羽', '劉備', '曹操', '孫權', '關羽', '張飛', '呂布', '周瑜', '趙雲', '龐統', '司馬懿', '黃忠', '馬超']
[11]: names
['諸葛亮',
 '關羽',
 '劉備',
 '曹操',
 '孫權',
 '關羽',
 '張飛',
 '呂布',
 '周瑜',
 '趙雲',
 '龐統',
 '司馬懿',
 '黃忠',
 '馬超']

古錠刀
衝鋒槊
丈八長標
王雙大刀
呂度刀
[25]: weapons_origin = data_weapon.split('\n')
[26]: print(weapons_origin[:40])
['青龍偃月刀', '', '丈八點鋼矛', '', '藤脊蛇矛', '', '涯角槍', '', '諸葛槍', '', '方天畫戟', '', '長柄鐵鏈', '', '鐵鞭響背斧', '', '大斧', '', '龍金斧', '', '三尖刀', '', '截頭大刀', '', '馬岱寶刀', '', '古錠刀', '', '衝鋒槊', '', '丈八長標', '', '王雙大刀', '', '呂度刀', '', '龍泉劍', '', '倚天劍', '']
[27]: weapons = []
[28]: for weapon in weapons_origin:
    if weapon != '':
        weapons.append(weapon)
[29]: weapons[:500]
[29]: ['青龍偃月刀',
 '丈八點鋼矛',
 '藤脊蛇矛',
 '涯角槍',
 '諸葛槍',
 '方天畫戟',
 '長柄鐵鏈',
 '鐵鞭響背斧',
 '大斧',
 '龍金斧',
 ...]
```

第二讲 词频统计

3.链接功勋科学家：把ppt中的文本换成功勋科学家黄旭华院士的传记序言文本（文件夹中，科学家博物馆-黄旭华传记序言.txt），1）统计全文词频；2）统计指定词频，如“黄旭华”；

```
[12]: {'张金麟': 1,
      '性能': 2,
      '由于': 1,
      '这里': 1,
      '中国科协': 1,
      '主题': 1,
      '学生': 3,
      '伟大': 1,
      '广东省': 2,
      '之所以': 1,
      '评价': 2,
      '先进': 1,
      '回答': 1,
      '分析': 3,
      '第一代': 8,
      '通过': 1,
      '核讹诈': 1,
      '主题': 1}

[13]: articlelist = sorted(articleDict.items(),key = lambda x:x[1], reverse = True) # 对词典中的词排序

[14]: # 输出词频的前100个
      for i in range(100):
          print(articlelist[i])

('黄旭华', 53)
('核潜艇', 32)
('采集', 29)
('学术', 22)
('资料', 21)
('工作', 17)
('成长', 15)
('小组', 14)
('专业', 13)
('进行', 13)
('院士', 13)
('研制', 12)
('我国', 12)
('技术', 12)
('工程', 11)
```

```
return count

except FileNotFoundError:
    print(f"错误: 找不到文件 '{filename}'")
    return None
except Exception as e:
    print(f"读取文件时发生错误: {e}")
    return None

# 使用函数
if __name__ == "__main__":
    filename = "科学家博物馆-黄旭华传记序言.txt"
    result = count_huangxuhua(filename)

    if result is not None:
        print(f"\n统计完成!")
```

```
=====
文件: 科学家博物馆-黄旭华传记序言.txt
“黄旭华”出现的次数: 59
=====
```

详细统计:

文本总字符数: 4030

“黄旭华”出现位置: [101, 200, 246, 308, 390, 483, 617, 819, 850, 871, 945, 1198, 1500, 1554, 1578, 1602, 1653, 1815, 1834, 1878, 1948, 1977, 2039, 2085, 2135, 2313, 2326, 2340, 2396, 2415, 2434, 2501, 2534, 2703, 2805, 2825, 2856, 2907, 2926, 2971, 3038, 3054, 3108, 3141, 3176, 3268, 3315, 3341, 3437, 3491, 3597, 3616, 3684, 3703, 3753, 3810, 3856, 3902, 3983]

统计完成!

第二讲 词频统计

4.阅读论文“2018-Wang 等 - Long live the scientists Tracking the scientific”，并做阅读总结（1页PPT即可）。

本文通过分析谷歌图书和谷歌学术中物理学家的名字出现频率，追踪了伟大科学家的长期科学声望及其演变。研究发现，像牛顿和爱因斯坦这样的科学巨匠虽已逝世，但其学术影响力跨越世纪，至今仍被广泛提及。此外，研究揭示了“同群体偏好”现象，即科学家在本国或使用同一语言的群体中享有更高的声望。这表明，基于图书的数字化语料分析能够为衡量科学家在学术之外的社会影响力提供新的视角。

研究进一步通过共现分析探讨了科学家最为人熟知的科学贡献。牛顿的名字常与万有引力和运动定律同时出现，而爱因斯坦则与相对论和量子理论紧密关联。此外，研究还列出了21世纪最具声望的20位物理学家，其中爱因斯坦、普朗克、牛顿等人位居前列，说明早期科学家的影响力在当代依然显著。

尽管该方法在评估科学家长期声望方面具有潜力，但研究也指出了若干局限性，包括数据中的语言偏见、姓名歧义问题，以及无法区分名字出现在书中的具体语境等。未来研究可进一步拓展至多学科领域，区分学术与公众影响力，并探索将谷歌图书数据作为替代计量学来源的可能性，以更全面地评估科学家对社会的广泛贡献。

第三讲 词云与可视化

[词云图，文字云，文字生图，在线免费生成](#)

1. 用任意一款词云工具，制作一个好看的词云（内容合理即可），并对词云图有一段话的解释。



这张闲鱼手机类商品标题词云图直观地展示了该平台手机交易中的核心关注点和描述高频词汇。图中最大、最突出的词汇如“电池”“国行”“苹果”“Pro”“拍照”“功能”等，直接点明了买家与卖家最关心的交易要素：手机的品牌与型号（以苹果及其Pro版本为典型）、国行身份、电池状况、拍摄功能等。

“不换”一词以极高的频率出现，并与“原装”“边框”“贴纸”等词汇紧密关联，这强烈反映了二手手机交易中的一个普遍心态和描述重点——卖家倾向于强调手机部件的“原装”性，并反复申明某些部件“不换”（即未经更换或维修），以此作为设备成色好、无拆修、值得信赖的关键卖点，从而降低买家的顾虑并提升商品的吸引力。


第三讲 词云与可视化

2. 使用Echarts，制作3个以上图，其中一个必须是“关系”，图的概念越明确（可解释，而不是自带的模板）越好。

1.李白的关系图




2.二手手机瑕疵分布玫瑰图



第三讲 词云与可视化

2. 使用Echarts，制作3个以上图，其中一个必须是“关系”，图的概念越明确（可解释，而不是自带的模板）越好。

3.二手图书商家分布统计图




第三讲 词云与可视化

[CiteSpace Home](#)

3. 使用Gehpi、VOSViewer、CiteSpace…其中任意一款工具，绘制任意你感兴趣的图谱1-2张。

CiteSpace关键词聚类图谱

关键词聚类图谱通过模块化聚类算法，将语义相近、关联紧密的关键词聚为一类，能够清晰呈现二手消费领域的核心研究主题与各主题的内涵特征。



第三讲 词云与可视化

4. 采用给的程序，实现一段科学家文本的词云图绘制，越清晰越好（生成的词云图要单独拿出来）。



第四讲 情感分析

1.使用PPT给的情感分析平台（或其它平台），对文本情感进行分析，并截图；



第四讲 情感分析

2. 完成sentiment_analysis_1-sentiment_analysis_4, 4份代码。做截图，并简要做代码运行总结分析。

```
[1]: text = "I am happy today. I feel sad today."

[2]: from textblob import TextBlob
blob = TextBlob(text)

[3]: blob

[3]: TextBlob("I am happy today. I feel sad today.")

[4]: # 原封不动的打印出来了?
# 实际上已经把文本分成了句子了，看一看
blob.sentences

[4]: [Sentence("I am happy today."), Sentence("I feel sad today.")]

[5]: blob.sentences[0].sentiment

[5]: Sentiment(polarity=0.8, subjectivity=1.0)

[6]: # 上面的结果什么意思呢?
# 情感极性0.8，主观性1.0。说明一下，情感极性的变化范围是[-1, 1]，-1代表完全负面，1代表完全正面。
# 我表达的是我很高兴，那么这个结果是对的

[7]: blob.sentences[1].sentiment

[7]: Sentiment(polarity=-0.5, subjectivity=1.0)

[8]: # 整段文本的情感呢?
blob.sentiment

[8]: Sentiment(polarity=0.15000000000000002, subjectivity=1.0)

[9]: # 你可能会觉得没有道理。怎么一句“高兴”，一句“沮丧”，合起来最后会得到正向结果呢?
# 首先不同极性的词，在数值上是有区别的。我们应该可以找到比“沮丧”更为负面的词汇。而且这也符合逻辑，谁会这么“天上一脚，地下一脚”矛盾地描
```

```
[11]: text_cn = u"我今天很快乐，我今天很愤怒。"

[12]: #注意在引号前面我们加了一个字u，它很重要。因为它提示Python，“这一段我们输入的文本编码格式是Unicode，别搞错了哦”。至于文本编码格式的细节，有机会我们再详细聊。

[13]: from snownlp import SnowNLP

[14]: senti_cn = SnowNLP(text_cn)

[15]: # 看看snownlp包的分句能力
for sentence in senti_cn.sentences:
    print(sentence)

我今天很快乐
我今天很愤怒

[16]: senti_cn_1 = SnowNLP(senti_cn.sentences[0])

[17]: # 一个细节上的问题，英文是x.sentiment，中文是x.sentiments，多了一个s
# 另外，在句法上和英文的也略有不同，比如直接用语句：senti_cn.sentences[0].sentiments是会报错的
senti_cn_1.sentiments

[17]: 0.971889316039116

[18]: senti_cn_2 = SnowNLP(senti_cn.sentences[1])

[19]: senti_cn_2.sentiments

[19]: 0.07763913772213482

这里你肯定发现了问题——“愤怒”这个词表达了如此强烈的负面情感，为何得分依然是正的?

这是因为SnowNLP和textblob的计分方法不同。SnowNLP的情感分析取值，表达的是“这句话代表正面情感的概率”。也就是说，对“我今天很愤怒”一句，SnowNLP认为，它表达正面情感的概率很低很低。

这样解释就是ok了

[20]: senti_cn.sentiments

[20]: 0.7237619924203508
```

第四讲 情感分析

作业

注：设计课程的时候，可以把作业单独拿出来，放在另外一个文档中

从淘宝或者其他平台上找一些评论的句子来试一试，它的情感值是多少。

```
[22]: # 例如
text_taobao_1 = "显示效果：挺好的 运行速度：目前来说很流畅 拍照效果：拍照效果挺好的 电池续航：一天一冲 总结：目前没啥毛病，用了一天的体验"

[23]: taobao_1 = SnowNLP(text_taobao_1)

[24]: taobao_1.sentiments
[24]: 0.999947261146611

[25]: text_taobao_2 = "总结：这是我买过最不满意的一款手机！两千多元的手机这样，真的很不值！"

[26]: taobao_2 = SnowNLP(text_taobao_2)

[27]: for sentence in taobao_2.sentences:
      print(sentence)
      总结：这是我买过最不满意的一款手机
      两千多元的手机这样
      真的很不值

[28]: taobao_2.sentiments
[28]: 0.889005139666256

[29]: # 以上的结果看上去是有问题的。分析的不准确。

[30]: text_taobao_3 = "显示效果：像素不行 运行速度：微信有时发给不了语音，得重新开机后才能发，才买半个月的手机就这样，客服态度也很差！ 拍照效果：拍照不清晰！ 电池续航：手机

[31]: taobao_3 = SnowNLP(text_taobao_3)

[32]: taobao_3.sentiments
[32]: 5.7076094222563434e-05
```

Analysis_1总结分析

- 1.不同极性的词，在数值上是有区别的
 2. SnowNLP和textblob的计分方法不同。
- SnowNLP的情感分析取值，表达的是“这句话代表正面情感的概率”。也就是说，对“我今天很愤怒”一句，SnowNLP认为，它表达正面情感的概率很低很低。

第四讲 情感分析

```
[1]: import pandas as pd # pandas用来处理表格数据的工具包

[2]: df = pd.read_excel("restaurant-comments.xlsx")

[3]: df.head()

[3]:
```

	comments	
0	这辈子最爱吃的火锅，一星期必吃一次啊！最近才知道他家还有免费鸡蛋羹.....炒鸡好吃炒鸡嫩...	2017-05-
1	第N次来了，还是喜欢?..... 从还没上A餐厅的楼梯开始，服务员已经在那迎宾了，然...	2017-05-
2	大姨过生日，姐姐定的这家A餐厅的包间，服务真的是没得说，A餐厅的服务也是让我由衷的欣赏，很久...	2017-04-
3	A餐厅的服务哪家店都一样，体贴入微。这家店是我吃过的排队最短的一家，当然也介于工作日且比较晚...	2017-04-
4	因为下午要去天津站接人，然后我倩前几天就说想吃A餐厅，然后正好这有，就来这吃了。 来的...	2017-05-

```
# 注意这里的时间列。如果你的Excel文件里的时间格式跟此处一样，包含了日期和时间，那么Pandas会非常智能地帮你
反之，如果你获取到的时间只精确到日期，例如"2017-04-20"这样，那么Pandas只会把它当做字符串，后面的时间序列分

from dateutil import parser
df["date"] = df.date.apply(parser.parse)

这样，你就获得了正确的时间数据了

[4]: text = df.comments.iloc[0] # iloc是索引（用来定位到指定的位置），这里就是第一条评论文本

[5]: text

[5]: '这辈子最爱吃的火锅，一星期必吃一次啊！最近才知道他家还有免费鸡蛋羹.....炒鸡好吃炒鸡嫩啊！！新出的红皮土豆
们半份豆花是4块儿，一份豆花是6块儿，点两个半份比较合适，太实在了哈哈哈，每次妈妈说开心果好吃服务员都给我们

[6]: from snownlp import SnowNLP

[7]: s = SnowNLP(text)

[8]: s.sentiments

[8]: 0.4244401030222834
```

```
[9]: def get_sentiment_cn(text):
    s = SnowNLP(text)
    return s.sentiments # snownlp是通用的，就没那么准确

然后，我们利用Python里面强大的apply语句，来一次性处理所有评论，并且将生成的情感数值在数据框里面单独存为一列，称为sentiment。

[10]: df["sentiments"] = df.comments.apply(get_sentiment_cn) #这行代码很有意思！

[11]: df.head(100)

[11]:
```

	comments	date	sentiments
0	这辈子最爱吃的火锅，一星期必吃一次啊！最近才知道他家还有免费鸡蛋羹.....炒鸡好吃炒鸡嫩...	2017-05-14 16:00:00	4.244401e-01
1	第N次来了，还是喜欢?..... 从还没上A餐厅的楼梯开始，服务员已经在那迎宾了，然...	2017-05-10 16:00:00	4.506914e-01
2	大姨过生日，姐姐定的这家A餐厅的包间，服务真的是没得说，A餐厅的服务也是让我由衷的欣赏，很久...	2017-04-20 16:00:00	1.000000e+00
3	A餐厅的服务哪家店都一样，体贴入微。这家店是我吃过的排队最短的一家，当然也介于工作日且比较晚...	2017-04-25 16:00:00	1.182003e-01
4	因为下午要去天津站接人，然后我倩前几天就说想吃A餐厅，然后正好这有，就来这吃了。 来的...	2017-05-21 16:00:00	8.712261e-01
5	A餐厅是我们的定点单位，单位大聚小聚都来这，所以享受VIP待遇，来了不用等位。这菜品新鲜，...	2017-05-05 16:00:00	9.980202e-01
6	这两天风特别大，家里也没什么可吃的，外卖也不知道吃什么！又懒得出去，发现好久没吃火锅啦！灵机...	2017-04-22 16:00:00	9.820584e-01
7	A餐厅真的是天津每一个店我都来过无数次了！ 今天觉得我拍的图很好看hhhh于是就来发条...	2017-05-20 16:00:00	6.392747e-03
8	今天又来到新开路的A餐厅，食材还是非常新鲜，羔羊肉味道鲜美，墨鱼滑味道新鲜！我们一家三口吃的...	2017-05-12 16:00:00	4.267672e-02
9	服务态度一如既往的好，看我东西多，主动帮忙提东西，所有的服务员都主动打招呼，非常热情。我点的...	2017-05-07 16:00:00	6.235047e-01
10	服务好赞！外送小哥实际A餐厅自己配的，送之前一个电话说着急已经在送的路上，送到后也一个电话说...	2017-04-10 16:00:00	1.965386e-04
11	服务一如既往的这么赞、论食材是火锅中的精粹，论服务也绝对是龙头老大！人多最爱来吃A餐厅了、每...	2017-04-23 16:00:00	9.999997e-01
12	一直特别特别特别爱A餐厅真的服务太贴心了细节决定一切呀用餐的时候接了个电话无意中跟朋友说今天...	2017-05-07 16:00:00	9.999998e-01
13	服务没的说啊，非常的周到啊，从始至终不用自己喊服务员，主动的倒饮料，帮我们下肉，吃完还给我们...	2017-05-14 16:00:00	9.999515e-01
14	口味还不错?点了一份蛋炒饭，加荷包蛋?清心的。捞派捞面?还不错，菌汤番茄?的都好吃。炸馒头一...	2017-05-14 16:00:00	9.999862e-01

第四讲 情感分析

新的列sentiment已经生成。我们之前介绍过，SnowNLP的结果取值范围在0到1之间，代表了情感分析结果为正面的可能性。通过客对这家分店评价总体上还是正面的，而且有的评论是非常积极的。

但是少量数据的观察，可能造成我们结论的偏颇。我们来把所有的情感分析结果数值做一下平均。使用mean()函数即可。

```
[12]: df.sentiments.mean()
```

```
[12]: 0.6987503312852683
```

整体接近0.7，正面。我们再来看看中位数值，使用的函数为median()。

```
[13]: df.sentiments.median()
```

```
[13]: 0.9270364310550024
```

我们发现了有趣的现象——中位数值不仅比平均值高，而且几乎接近1（完全正面）。这意味着，大部分的评价一边倒表示非常满意。但是存在着少部分异常点，显著拉低了平均值。下面我们用工感的时间序列可视化功能，直观查看这些异常点出现在什么时间，以及它们的数值究竟有多低。

我们需要使用ggplot绘图工具包。这个工具包原本只在R语言中提供，让其他数据分析工具的用户羡慕得流口水。幸好，后来它很快


我们从ggplot中引入绘图函数，并且让Jupyter Notebook可以直接显示图像。

```
[14]: %pylab inline
```


```
%pylab is deprecated, use %matplotlib inline and import the required libraries.  
Populating the interactive namespace from numpy and matplotlib
```

```
D:\anaconda\Lib\site-packages\IPython\core\magics\pylab.py:166: UserWarning: pylab import has clobbered these variables  
`%matplotlib` prevents importing * from pylab and numpy  
warn("pylab import has clobbered these variables: %s" % clobbered +
```

```
[15]: import matplotlib.pyplot as plt  
#plt.scatter(df["date"],df["sentiments"],color='blue',figsize=(10,12))  
plt.figure(figsize=(10, 12))  
plt.scatter(df["date"],df["sentiments"],color='blue')  
df = df.sort_values("date")  
plt.plot(df["date"],df["sentiments"],color='red',linestyle='--',linewidth=1)  
plt.show()
```



第四讲 情感分析



```
[16]: plt.savefig('timeline.png') # 看不到? 改一改?
```

在图中，我们发现许多正面评价情感分析数值极端的高。同时，我们也清晰地发现了那几个数值极低的点。对应评论的情感分析数值接近于0。这几条评论，被Python判定为基本上没有正面情感了。

从时间上看，最近一段时间，几乎每隔几天就会出现一次比较严重的负面评价。

作为经理，你可能如坐针毡。希望尽快了解发生了什么事。你不用在数据框或者Excel文件里面一条条翻找情感数值最低的评论。Python数据框Pandas为你提供了非常好的排序功能。假设你希望找到所有评论里情感分析数值最低的那条，可以这样执行：

```
[17]: df.sort_values(['sentiments'])(:1]
```

```
[17]:
```

	comments	date	sentiments
24	这次是在情人节当天过去的，以前从来没在情人节正日子出来过，不是因为没男朋友，而是感觉哪哪人...	2017-02-20 16:00:00	6.334066e-08

情感分析结果数值几乎就是0啊！不过这里数据框显示评论信息不完全。我们需要将评论整体打印出来。

```
[18]: print(df.sort_values(['sentiments']).iloc[0].comments)
```

这次是在情人节当天过去的，以前从来没在情人节正日子出来过，不是因为没男朋友，而是感觉哪哪人都多，所以特意错开，这次实在是馋A餐厅了，所以赶在正日子也出来了，从下午四点多的时候我看排号就排到一百多了，我从家开车过去得堵的话一个小时，我一看提前两个小时就在网上先排着号了，差不多我们是六点半到的，到那时候我看号码前面还有才三十多号，我想着肯定没问题了，等一会就能吃上的，没想到悲剧了，就从我们到那坐到等位区开始，大约是十分二十分一叫号，中途多次我都想走了，哈哈，哎，等到最后早上九点才吃上的，服务员感觉也没以前清闲时周到了，不过这肯定的，一人负责好几桌，今天节日这么多人，肯定是很累的，所以大多也都是我自己跑腿，没让服务员给弄太多，就虾滑让服务员下的，然后环境来说感觉卫生方面是不错，就是有些太吵了，味道还是一如既往的那个味道，不过A餐厅最人性化的就是看我们等了两个多小时，上来送了我们一张打折卡，而且当次就可以使用，这点感觉还是挺好的，不愧是A餐厅，就是比一般的要人性化，不过这次就是选错日子了，以后还是得提前预约，要不就别赶节日去，太火爆了！

Analysis_2总结分析

- 1.从ggplot中引入绘图函数，并且让Jupyter Notebook可以直接显示图像。
- 2.结果不合理：自然语言的分析，不仅要看表达强烈情感的关键词，也需要考虑到表述方式和上下文等诸多因素。

第四讲 情感分析

```
[1]: import requests
import json

# DeepSeek API 端点
url = "https://api.deepseek.com/v1/chat/completions"

# 替换为您的 DeepSeek API 密钥
API_KEY = "sk-84b7446314044a30bd774d473955ba07" # 直接复制过来

# 请求头, 包含 API 密钥和内容类型
headers = {
    "Authorization": f"Bearer {API_KEY}",
    "Content-Type": "application/json"
}

[2]: # 患者描述文本
text = (
    "我今年58岁, 退休后感到生活失去了重心, 开始出现失眠、头痛和疲乏无力的症状。"
    "后来, 皮肤变得异常敏感, 连衣服的触碰都像针扎一样疼痛。"
    "我常常感到心慌、胸闷, 背部沉重得像压了一块石头。"
    "对光线和声音变得极度敏感, 电话铃声都会让我惊恐。"
    "多次到医院检查, 结果都显示没有器质性疾病。"
    "我变得不愿出门, 不想与人交流, 整天把自己关在屋里, 拉紧窗帘, 感觉生活毫无意义。"
)

# 构建提示词, 要求模型提取细粒度情感实体
prompt = (
    "请从以下患者描述中提取出具体的身体部位、症状以及对应的情感状态, "
    "并以 JSON 格式返回, 格式如下: "
    "{ '实体': [ { '部位': '...', '症状': '...', '情感': '...' }, ... ] }\n\n"
    f"患者描述: {text}"
)

[3]: # 请求体, 包含模型参数和提示词
data = {
    "model": "deepseek-chat",
    "messages": [
        { "role": "user", "content": prompt }
    ],
    "temperature": 0.3
}
```

```
try:
    # 发送 POST 请求
    response = requests.post(url, headers=headers, data=json.dumps(data))

    # 检查响应状态码
    if response.status_code == 200:
        # 解析 JSON 响应
        result = response.json()
        # 提取模型生成的内容
        generated_text = result['choices'][0]['message']['content']
        print("细粒度情感实体抽取结果:")
        print(generated_text)
    else:
        # 处理错误响应
        print(f"请求失败, 状态码: {response.status_code}")
        print(f"错误信息: {response.text}")

except requests.exceptions.RequestException as e:
    # 处理网络请求异常
    print(f"网络请求失败: {e}")
except json.JSONDecodeError as e:
    # 处理 JSON 解析异常
    print(f"JSON 解析失败: {e}")
except Exception as e:
    # 处理其他异常
    print(f"发生未知错误: {e}")
```

细粒度情感实体抽取结果:

```
{
  "实体": [
    {
      "部位": "全身",
      "症状": "失眠",
      "情感": "失去重心"
    },
    {
      "部位": "头部",
      "症状": "头痛",
      "情感": "疲乏无力"
    },
    {
      "部位": "皮肤",
      "症状": "异常敏感, 触碰如针扎疼痛",
      "情感": "不适"
    },
  ],
}
```

Analysis_3总结分析

1.配合使用大模型API,可辅助多领域工作

2.我认为大语言模型在识别患者的身体、心理、情感的工作中, 表现良好

```
{
  "部位": "皮肤",
  "症状": "异常敏感, 触碰如针扎疼痛",
  "情感": "不适"
},
{
  "部位": "心脏",
  "症状": "心慌",
  "情感": "惊恐"
},
{
  "部位": "胸部",
  "症状": "胸闷",
  "情感": "沉重"
},
{
  "部位": "背部",
  "症状": "沉重如压石头",
  "情感": "压抑"
},
{
  "部位": "感官",
  "症状": "对光线和声音极度敏感",
  "情感": "惊恐"
},
{
  "部位": "行为",
  "症状": "不愿出门, 不与人交流, 关在屋里拉紧窗帘",
  "情感": "生活无意义"
}
]
```

第四讲 情感分析

```
[1]: import re

with open("背影.txt", "r", encoding="utf-8") as f:
    text = f.read()

# 按照句号、感叹号进行分句（保留标点）
sentences = re.split(r'(?<=[。！])', text)
sentences = [s.strip() for s in sentences if s.strip()]
numbered_sentences = [(i + 1, s) for i, s in enumerate(sentences)]
#numbered_sentences = numbered_sentences[0:5] #大模型抽取很慢，提取文本的前n条句子

for num, sent in numbered_sentences:
    print(f"{num}: {sent}")
```

1: 我与父亲不相见已二年余了，我最不能忘记的是他的背影。
2: 那年冬天，祖母死了，父亲的差使也交卸了，正是祸不单行的日子。
3: 我从北京到徐州，打算跟着父亲奔丧回家。
4: 到徐州见着父亲，看见满院狼籍的东西，又想起祖母，不禁簌簌地流下眼泪。
5: 父亲说：“事已如此，不必难过，好在天无绝人之路！”
6: ”
回家变卖典质，父亲还了亏空；又借钱办了丧事。
7: 这些日子，家中光景很是惨澹，一半为了丧事，一半为了父亲赋闲。
8: 丧事完毕，父亲要到南京谋事，我也要回北京念书，我们便同行。
9: 到南京时，有朋友约去游逛，勾留了一日；第二日上午便须渡江到浦口，下午上车北去。
10: 父亲因为事忙，本已说定不送我，叫旅馆里一个熟识的茶房陪我同去。
11: 他再三嘱咐茶房，甚是仔细。
12: 但他终于不放心，怕茶房不妥帖；颇踌躇了一会。
13: 其实我那年已二十岁，北京已来往过两三次，是没有什么要紧的了。
14: 他踌躇了一会，终于决定还是自己送我去。
15: 我再三劝他不必去；他只说：“不要紧，他们去不好！”
16: ”
我们过了江，进了车站。
17: 我买票，他忙着照看行李。
18: 行李太多了，得向脚夫DD行些小费才可过去。
19: 他便又忙着和他们讲价钱。
20: 我那时真是聪明过分，总觉得他说话不大漂亮，非自己插嘴不可，但他终于讲定了价钱；就送我上车。
21: 他给我拣定了靠车门的一张椅子；我将他给我做的紫毛大衣铺好座位。
22: 他嘱我路上小心，夜里要警醒些，不要受凉。
23: 又嘱托茶房好好照应我。
24: 我心里暗笑他的迂；他们只认得钱，托他们只是白托！
25: 而且我这样大年纪的人，难道还不能料理自己么？我现在想想，我那时真是太聪明了。

26: 我说道：“爸爸，你走吧。”
27: ”他往车外看了看，说：“我买几个橘子去。”
28: 你就在此地，不要走动。
29: ”我看那边月台的栅栏外有几个卖东西的等着顾客。
30: 走到那边月台，须穿过铁道，须跳下去又爬上去。
31: 父亲是一个胖子，走过去自然要费事些。
32: 我本来要去的，他不肯，只好让他去。
33: 我看见他戴着黑布小帽，穿着黑布大马褂，深青布棉袍，蹒跚DD地走到铁道边，慢慢探身下去，尚不大难。
34: 可是他穿过铁道，要爬上那边月台，就不容易了。
35: 他用两手攀着上面，两脚再向上缩；他肥胖的身子向左微倾，显出努力的样子。
36: 这时我看见他的背影，我的泪很快地流下来了。
37: 我赶紧拭干了泪。
38: 怕他看见，也怕别人看见。
39: 我再向外看时，他已抱了朱红的橘子往回走了。
40: 过铁道时，他先将橘子散放在地上，自己慢慢爬下，再抱起橘子走。
41: 到这边时，我赶紧去搀他。
42: 他和我走到车上，将橘子一股脑儿放在我的皮大衣上。
43: 于是扑扑衣上的泥土，心里很轻松似的。
44: 过一会儿说：“我走了，到那边来信！”
45: ”我望着他走出去。
46: 他走了几步，回过头看见我，说：“进去吧，里边没人。”
47: ”等他的背影混入来来往往的人里，再找不着了，我便进来坐下，我的眼泪又来了。
48: 近几年来，父亲和我都是东奔西走，家中光景是一日不如一日。
49: 他少年出外谋生，独力支持，做了许多大事。
50: 哪知老境却如此颓唐！
51: 他触目伤怀，自然情不能自己。
52: 情郁于中，自然要发之于外；家庭琐屑便往往触他之怒。
53: 他待我渐渐不同往日。
54: 但最近两年不见，他终于忘却我的不好，只是惦记着我，惦记着我的儿子。
55: 我北来后，他写了一信给我，信中说道：“我身体平安，惟膀子疼痛厉害，举箸提笔，诸多不便，大约大去之期不远矣。”
56: ”我读到此处，在晶莹的泪光中，又看见那肥胖的、青布棉袍黑布马褂的背影。
57: 唉！
58: 我不知何时再能与他相见！

第四讲 情感分析

```
[2]: import requests
import time
import re

API_KEY = "sk-84b7446314044a30bd774d473955ba07" # 替换成你自己的密钥
API_URL = "https://api.deepseek.com/v1/chat/completions"

headers = {
    "Content-Type": "application/json",
    "Authorization": f"Bearer {API_KEY}"
}

emotion_results = []

for num, sent in numbered_sentences:
    prompt = f"""你是一个情感分析助手。请对下面这句话做如下分析：

1. 提取或生成一个最能代表情绪的词语（只能一个）；
2. 对整句话的情绪进行打分，范围是 -1（非常负面）到 1（非常正面），中性为 0。

直接用如下格式输出：
情感词: XXX
情感值: X.X

句子: {sent}"""

    data = {
        "model": "deepseek-chat",
        "messages": [{"role": "user", "content": prompt}],
        "temperature": 0.3
    }

    try:
        response = requests.post(API_URL, headers=headers, json=data)
        time.sleep(0.1) # 控制请求频率

        if response.status_code == 200:
            content = response.json()['choices'][0]['message']['content']

            # 宽容匹配格式，如：情感词: 悲伤、情感值: -0.6
            match = re.search(r"情感词[：:]? ]?\s*([^\n\r: :\\s+)]\s*\n\r)+情感值[：:]? ]?\s*(-?\d+(?:\.\d+)?)", content)
            if match:
                word = match.group(1)
                score = float(match.group(2))
                emotion_results.append((num, sent, word, score))
```

```
    else:
        print(f"[⚠️ 无法匹配] 第{num}句: {sent}")
        print("模型输出: ", content)
        emotion_results.append((num, sent, "无", 0.0))

    else:
        print(f"[❌ API错误] {response.status_code}")
        print(response.text)
        emotion_results.append((num, sent, "无", 0.0))

except Exception as e:
    print(f"[异常] 第{num}句处理失败: {e}")
    emotion_results.append((num, sent, "无", 0.0))

[3]: for item in emotion_results:
    print(f"句子{item[0]}: 情感词: {item[2]}, 情感值: {item[3]}")

句子1: 情感词: 怀念, 情感值: 0.2
句子2: 情感词: 悲伤, 情感值: -0.8
句子3: 情感词: 悲伤, 情感值: -0.8
句子4: 情感词: 悲伤, 情感值: -0.8
句子5: 情感词: 慰藉, 情感值: 0.3
句子6: 情感词: 悲凉, 情感值: -0.8
句子7: 情感词: 悲伤, 情感值: -0.8
句子8: 情感词: 平静, 情感值: 0.0
句子9: 情感词: 平静, 情感值: 0.0
句子10: 情感词: 平静, 情感值: 0.1
句子11: 情感词: 关切, 情感值: 0.3
句子12: 情感词: 担忧, 情感值: -0.5
句子13: 情感词: 淡然, 情感值: 0.1
句子14: 情感词: 犹豫, 情感值: 0.2
句子15: 情感词: 担忧, 情感值: -0.3
句子16: 情感词: 平静, 情感值: 0.0
句子17: 情感词: 中性, 情感值: 0.0
句子18: 情感词: 无奈, 情感值: -0.3
句子19: 情感词: 忙碌, 情感值: 0.0
句子20: 情感词: 自责, 情感值: -0.3
句子21: 情感词: 温暖, 情感值: 0.6
句子22: 情感词: 关怀, 情感值: 0.8
句子23: 情感词: 温暖, 情感值: 0.7
句子24: 情感词: 轻蔑, 情感值: -0.5
句子25: 情感词: 自嘲, 情感值: -0.3
句子26: 情感词: 不舍, 情感值: -0.3
句子27: 情感词: 温暖, 情感值: 0.6
句子28: 情感词: 关切, 情感值: 0.3
句子29: 情感词: 平静, 情感值: 0.0
句子30: 情感词: 疲惫, 情感值: -0.3
```

```
[4]: import matplotlib.pyplot as plt
from matplotlib import rcParams

# 设置中文字体（适配不同系统）
# plt.rcParams['font.family'] = 'SimHei' # 黑体, 适用于 Windows
plt.rcParams['font.family'] = 'Heiti TC' # mac对应的黑体
plt.rcParams['axes.unicode_minus'] = False # 解决负号 '-' 显示为方块的问题

# 如果你使用的是 macOS, 可换为:
# plt.rcParams['font.family'] = 'Heiti TC'

# 如果是 Linux (如 Ubuntu) 且安装了中文字体:
# plt.rcParams['font.family'] = 'Noto Sans CJK SC'


# 画图
x = [item[0] for item in emotion_results]
y = [item[3] for item in emotion_results]
labels = [item[2] for item in emotion_results]

plt.figure(figsize=(12, 6))
plt.plot(x, y, linestyle='--', marker='o', color='blue')

# 添加每个点的中文情感词标签
for i in range(len(x)):
    plt.text(x[i], y[i] + 0.05, labels[i], ha='center', fontsize=9)

plt.title("散文情感词时间序列图")
plt.xlabel("句子编号")
plt.ylabel("情感值 (-1 到 1)")
plt.ylim(-1.1, 1.1)
plt.grid(True)
plt.tight_layout()
plt.show()
```

第四讲 情感分析




Analysis_4总结分析

- 1.使用大语言模型，可以提取句子，每句话中的情感词，或者隐含的情感实体；
- 2.用大语言模型可以计算出，每一个情感词或者情感词所在句子的情感得分
- 3.可使用大语言模型绘制可视化图表

第六讲 知识图谱理念

1. 实际产业案例分析：使用3-5页PPT对“阿里商品大脑”、“美团大脑”、“丁香医生知识图谱”、“领英知识图谱”...其中任意一家机构/公司最新的知识图谱生态构建，进行简要介绍与分析。要求：需要是最新进展（不能复制课程PPT中的内容）；可以是一个简单的案例；有自己的评价。自由发挥。（营销、信管，都可以结合自己的专业兴趣，自由选择分析对象）

第六讲 知识图谱理念



阿里商品大脑

输入“我要一件保暖的羽绒服” 测试智能导购

第六讲 知识图谱理念

介绍

阿里巴巴“商品大脑”是面向超大规模电商平台的商品信息治理与智能服务系统，旨在解决传统电商平台面临的商品信息标准化缺失、质量参差不齐、数据价值未充分挖掘等核心痛点。作为阿里巴巴数字商业操作系统的基础设施之一，商品大脑承担着平台治理、商家赋能、消费体验升级三重使命。

与早期版本相比，最新的商品大脑已从单一的商品知识库，演进为融合知识图谱、多模态AI和产业大模型的综合智能中枢。据阿里巴巴公开资料显示，该系统已覆盖超过10亿级商品SKU，日均处理商品信息更新数千万次，成为全球规模最大、最复杂的商品知识图谱应用之一。

第六讲 知识图谱理念

平台治理

1. 自动化商品审核：将人工审核占比从**30%**降至不足**5%**，审核效率提升约**15**倍，尤其对“标题党”、虚假宣传等传统难题识别准确率超过**95%**。
2. 智能属性标准化：为商家提供“一稿多发”的智能能力——上传一次商品信息，系统自动适配不同渠道（淘宝、天猫、海外站等）的格式要求，减少商家重复劳动。
3. 供应链知识挖掘：通过分析商品知识图谱中的制造地、材料、工艺等属性关系，为平台和商家提供产业带洞察，例如发现“广东小家电产业带”与“江浙面料产业带”的潜在合作机会。

第六讲 知识图谱理念

现状

- 1.阿里的淘宝系统，主要是以关键词（字）的方式对产品进行组织，采用“字面匹配”的方式，提供给用户产品；
- 2.阿里商品大脑，依然植入到淘宝系统，拥有了一定的智能性，通过**知识图谱**组织商品，对商品进行语义分析，实现智能导购；

不足


- 1.长尾商品理解不足：对于极其小众或新兴品类的商品，系统仍依赖规则和人工干预，AI泛化能力有待提升。
- 2.多平台标准差异：国内电商平台间的数据壁垒依然存在，跨平台商品知识统一面临挑战。
- 3.动态定价与知识静态性矛盾：商品知识图谱相对静态，但与实时价格、库存等动态数据的融合仍不够紧密。

未来发展趋势

- 1.从商品到产业的延伸：预计商品大脑将向上游供应链延伸，构建覆盖原材料、生产、物流的全产业链知识图谱。
- 2.个性化知识呈现：基于用户画像，为不同消费者呈现差异化的商品知识，例如向专业人士展示技术参数，向普通用户突出使用场景。
- 3.跨平台知识联邦：在隐私计算等技术保障下，探索与品牌方、其他平台的部分知识共享，提升整个电商行业的信息标准化水平。

第六讲（2） 知识图谱工具

1.使用PPT中知识图谱链接平台，检索、截图（大词林等，可用的）；




ppt中网页均无法使用

1.在DeepSeek中提问：“为‘新能源汽车产业链’创建知识图谱，用Mermaid格式”

2.复制代码到 <https://mermaid.live/>

第六讲（2） 知识图谱工具

2.使用白板建模绘制一个你感兴趣的“知识图谱”，可以是人物关系，也可以是事物关系，或者概念之间的关系等等，并解释你绘制的图谱；




[未命名绘图 - draw.io](#)

使用空白模版绘制了李白的
朋友圈

第六讲 (2) 知识图谱工具

3.使用echarts中的关系图，绘制作业2）中的“知识图谱”。



第六讲（2） 知识图谱工具

4.使用Neo4j（可在线版本），编程绘制一款（简单）知识图谱（内容不限）

